



**MATEMATICKO-FYZIKÁLNÍ
FAKULTA**
Univerzita Karlova

BAKALÁŘSKÁ PRÁCE

Adam Turčan

Webová aplikace pro konfigurovatelné zpracování textu s využitím externích služeb

Ústav formální a aplikované lingvistiky

Vedoucí bakalářské práce: doc. RNDr. Pavel Pecina, Ph.D.

Studijní program: Informatika

Studijní obor: Programování a vývoj software

Praha 2026

Prohlašuji, že jsem tuto bakalářskou práci vypracoval(a) samostatně a výhradně s použitím citovaných pramenů, literatury a dalších odborných zdrojů. Beru na vědomí, že se na moji práci vztahují práva a povinnosti vyplývající ze zákona č. 121/2000 Sb., autorského zákona v platném znění, zejména skutečnost, že Univerzita Karlova má právo na uzavření licenční smlouvy o užití této práce jako školního díla podle §60 odst. 1 autorského zákona.

V dne

Podpis autora

Poděkování.

Název práce: Webová aplikace pro konfigurovatelné zpracování textu s využitím externích služeb

Autor: Adam Turčan

Ústav: Ústav formální a aplikované lingvistiky

Vedoucí bakalářské práce: doc. RNDr. Pavel Pecina, Ph.D., Ústav formální a aplikované lingvistiky

Abstrakt: **Abstrakt.**

Klíčová slova: zpracování přirozených jazyků, uživatelské rozhraní, webová aplikace

Title: Web application for configurable text processing using external services

Author: Adam Turčan

Institute: Institute of Formal and Applied Linguistics

Supervisor: doc. RNDr. Pavel Pecina, Ph.D., Institute of Formal and Applied Linguistics

Abstract: **Abstract.**

Keywords: natural language processing, user interface, web application

Obsah

Úvod	7
Literatura	9
Zoznam obrázkov	10
Zoznam tabuliek	11
Seznam použitých zkratok	12
A Přílohy	13
A.1 První příloha	13

Červenou označujem skratky v texte, ktoré je potrebné vysvetliť.

Úvod

Vývoj softvérových nástrojov pre špecifické vedecké domény so sebou prináša unikátne výzvy. Vyžaduje nielen hlboké pochopenie doménových dát, ale aj schopnosť navrhnuť intuitívne používateľské rozhranie (**UI/UX**) pre používateľov, ktorí nemusia byť technicky zdatní. Zároveň však narážame na problém, že riešenia „šité na mieru“ jednej doméne sú často príliš úzko špecializované, a teda ťažko prenositeľné do iných oblastí.

Táto bakalárska práca sa zaoberá kompletným životným cyklom vývoja platformy určenej na spracovanie textu s využitím externých **NLP** služieb, akými sú preklad, segmentácia, anotácia a semantické značkovanie. Opisuje cestu od prvotného návrhu používateľskej skúsenosti (**UX**) pre potreby projektu MEMORISE, cez implementáciu počiatočnej architektúry, až po jej následnú evolúciu do podoby univerzálneho, konfigurovateľného systému. Práca tak neprezentuje len finálny stav, ale dokumentuje iteratívny proces, v ktorom prvá implementácia slúžila ako kľúčový prostriedok na identifikáciu architektonických nedostatkov a validáciu interakčného dizajnu.

Projekt MEMORISE a technologické výzvy

Táto práca je zasadená do kontextu medzinárodného výskumného projektu MEMORISE, ktorého cieľom je zachovanie spomienok obetí holokaustu a sprístupnenie ich príbehov pre budúce generácie. Vzhľadom na to, že priami svedkovia a pamätníci holokaustu postupne odchádzajú, projekt sa zameriava na digitalizáciu viac ako 80 000 historických záznamov, vrátane denníkov obetí, svedectiev a multimediálnych materiálov.

V rámci pracovných balíkov projektu zameraných na dátovú infraštruktúru a integráciu (**WP2 a WP3**) vzniká komplexný proces pre spracovanie týchto dát. Cieľom je transformovať neštruktúrované historické texty do podoby prepojených dát a znalostných grafov, ktoré následne slúžia ako podklad pre vizualizáciu.

Tento proces využíva pokročilé metódy umelej inteligencie a spracovania prirodzeného jazyka (**NLP**). Automatizované služby zabezpečujú:

- **Segmentáciu textu:** Rozdelenie dlhých textov (napríklad denníkov) na logické celky.
- **Strojový preklad:** Sprístupnenie dokumentov v rôznych jazykoch.
- **Semantické značkovanie:** Identifikáciu tém a kontextu.
- **Rozpoznávanie pomenovaných entít (ďalej ako NER):** Extrakciu mien osôb, geografických lokácií (napr. getá, tábory) a časových údajov.

Rola kurácie dát v **NLP** procesoch

Hoci moderné **NLP** modely dosahujú vysokú presnosť, pri práci s citlivými historickými dátami nie je plná automatizácia postačujúca. Výstupy modelov

často obsahujú chyby v rozpoznávaní entít (napr. zámena mena osoby za názov mesta), nepresnosti v preklade či nevhodnú segmentáciu, ktorá spôsobuje nelogické členenie textu a stratu kontextu. Tieto nedostatky by bez zásahu človeka mohli viesť k nesprávnej interpretácii historických faktov.

Ako uvádza metodika projektu MEMORISE (konkrétne **WP3** [1]), pre dosiahnutie vysokej kvality dát je nevyhnutný prístup *Human-in-the-loop*. To znamená, že automaticky generované metadáta musia byť validované a korigované ľudskými expertmi – kurátormi.

Pôvodná motivácia pre vznik tohto nástroja vychádzala práve z potreby poskytnúť expertom efektívne používateľské rozhranie pre:

- **Vizualizáciu výstupov z NLP API:** Prehľadné zobrazenie segmentov, prekladov a navrhovaných entít.
- **Post-editáciu prekladov a segmentácie:** Možnosť opraviť gramatické a kontextové nepresnosti vzniknuté pri strojovom preklade a segmentácii.
- **Validáciu anotácií:** Rýchlu korekciu nesprávne klasifikovaných entít a úpravu priradených semantických značiek.
- **Semantické prepájanie (Linking):** Manuálne dopĺňanie chýbajúcich väzieb na externé ontológie (napr. prepojenie na holandský tezaurus 2. svetovej vojny).

Potreba takéhoto rozhrania však nie je izolovaná len pre oblasť digitálnej histórie. S masívnym nástupom **NLP** a generatívnych modelov do praxe narážajú na identický problém mnohé iné domény, kde je kľúčová precíznosť dát – napríklad **medicína** (kontrola extrakcie symptómov z lekárskeho správ) alebo **právo** (validácia zmlúv a anonymizácia údajov). V týchto oblastiach, podobne ako v projekte MEMORISE, nemožno slepo dôverovať výstupom umelej inteligencie a prístup *Human-in-the-loop* sa stáva nevyhnutnosťou.

Vytvárať pre každú takúto doménu samostatnú, jednoúčelovú aplikáciu by však bolo neefektívne a dlhodobo neudržateľné. Existujúce riešenia často narážajú na limity flexibility – buď sú príliš všeobecné a nepokrývajú špecifické pracovné toky (ako je súbežná úprava segmentácie a prekladu), alebo sú naopak pevne naviazané na konkrétnu dátovú schému.

Motiváciou tejto práce je preto návrh a implementácia **univerzálnej, konfigurovateľnej platformy**. Cieľom je vytvoriť systém, ktorý dokáže dynamicky spracovávať výstupy z rôznych **NLP** služieb a prispôbiť sa odlišným anotačným schémam iba prostredníctvom zmeny konfigurácie, bez nutnosti zásahov do zdrojového kódu.

Literatura

1. MEMORISE CONSORTIUM. *MEMORISE Project Methodology: Work Package 3 – Data Infrastructure*. Dostupné tiež z: <https://memorise.sdu.dk/about-memorise/>. [Cit. 2024-02-05].

Zoznam obrázkov

Zoznam tabuliek

Seznam použitých zkratek

A Přílohy

A.1 První příloha